ChargeGrid Intelligence | Sprint 4

Relatório técnico de evolução · 23 de outubro de 2026

Integrantes: 1CCPH: Luigi Borgheti RM569958 ; 1CCA: Gabriel Savoy RM568991, Victor Vidigal RM571318, Raphael Tien RM570261.

O projeto evolui o assistente gerencial de recarga para consultar dados operacionais e PDFs com fontes verificáveis. O planejamento usa LCEL e contratos Pydantic; os cálculos continuam em Python. A entrega inclui avaliação rastreável e registra limitações de recuperação e completude.

Dimensão	Sprints 1/2 (versão original)	Sprint 04 (RAG avaliado)
Evidências	JSON da operação simulada	JSON e 3 PDFs com origem e página
Consulta	Análise operacional com prompt	Plano tipado; até 4 ferramentas
Recuperação	Sem índice documental	Chroma persistente e Nomic
Resposta	Schema operacional	Resposta documental/mista com apoios validados
Segurança	Guardrails de entrada e saída	Triagem documental e integridade de fontes
Avaliação RAG	Não medida	12 casos fixos; 2 iterações e 2 modelos
Scores por iteração	Não medidos	RAGAS Gemma A: F=0.917 (n=6), R=0.587 (n=10); B: F=1.000 (n=8), R=0.642 (n=11)
Qualidade do contexto	Sem avaliação documental	Proxy: âncoras recuperadas A 11/18; B 12/18; ainda há lacunas
Citação de fonte	Sem citação documental estruturada	Arquivo, página e trecho; visível em A 7/12 e B 8/12 casos

O fluxo operacional anterior permanece disponível. As métricas antigas de classificação não são tratadas como faithfulness ou relevância RAG. Os dados comerciais e as regras WeCharge são simulados e não representam políticas da GoodWe.

Arquitetura e evidências

Fluxo: pergunta → guardrails e histórico da sessão → planejador LCEL → plano Pydantic → executor Python → fontes documentais/operacionais → geração estruturada → conferência de citações e segurança → CLI ou Gradio.

Ingestão: PyMuPDFLoader → RecursiveCharacterTextSplitter → OllamaEmbeddings → Chroma local persistente. Base de 3 PDFs, 75 páginas e 254 chunks, com 600 caracteres, overlap de 200 e top-k 8. Identificadores, arquivo e página acompanham os trechos; reindexação evita duplicação.

As ferramentas consultam a operação, calculam indicadores, buscam documentos e estimam custos em Python. O histórico da sessão ajuda a interpretar a pergunta, mas respostas anteriores não viram evidência. Dados agregados não permitem descobrir valores de sessões individuais inexistentes na base.

Documentos são dados sem autoridade sobre o sistema. Conteúdo e metadados passam por triagem; identificadores reservados ou conflitantes são rejeitados. As citações precisam existir no contexto e preservar trechos literais. A proteção não garante detectar toda omissão ou conclusão semanticamente indevida.

Iteração A: busca semântica e prompts v2. Iteração B: prompts v3 preservam termos específicos; BM25 com k1=1,5 e b=0,75 reserva até duas posições lexicais e completa por fusão recíproca de rankings (constante 60), mantendo o limite total de oito chunks. Não usa gabarito para selecionar evidências.

O BM25 recalcula estatísticas do pequeno corpus por pergunta. O custo linear e a ausência de reconstrução de tabelas complexas são limitações para bases maiores. A extração não usa imagens e pode fragmentar relações entre linhas e colunas.

Avaliação comparável

Amostra pré-fixada de desenvolvimento: 6 perguntas respondíveis, 3 sem evidência completa e 3 ataques documentais, retirada do conjunto de 38. Uma execução por caso/configuração, sessão nova, mesmo corpus e gabarito; fixtures adversariais apenas em memória. Não é teste cego nem avaliação dos 38 casos completos.

Geração cloud: Gemma 4 31B e GPT-OSS 120B via Ollama. Temperature 0; top_p 0,9; limite de saída 1200 tokens; k=8; memória de 4000 tokens. Modelos B usam os mesmos prompts e busca, porém seus planejadores podem recuperar contextos distintos. Qwen ficou indisponível e foi substituído antes da rodada alternativa; não recebeu nota.

RAGAS 0.4.3 avalia os registros salvos com Gemma como juiz (temperatura 0, top_p 0,9, limite 4096 tokens) e Nomic para relevância (strictness 3). Usa o contexto pós-triagem efetivamente enviado à geração. Ambiente separado, com LangChain Community 0.4.1 para compatibilidade; API da aula marcada como deprecated, sem alterar o aplicativo.

Execução	Faithfulness RAGAS	Relevância RAGAS	Integral*	Falhas
A / Gemma	0.917 (n=6)	0.587 (n=10)	4/12	2
B / Gemma	1.000 (n=8)	0.642 (n=11)	3/12	1
B / GPT-OSS	0.952 (n=7)	0.537 (n=11)	3/12	1

Falhas técnicas são não aplicáveis nas duas métricas. Abstenções não recebem faithfulness por ausência de fatos; relevância pode ser zero mesmo numa recusa correta. Erros do juiz não viram zeros. Denominadores diferentes exigem examinar também o pareamento de casos válidos.

Comparação pareada Gemma: faithfulness: delta B-A +0.0833 (n=6); answer_relevancy: delta B-A +0.0347 (n=10). Os IDs e os rastros do juiz estão em evals/sprint4/ragas. Usar o mesmo modelo para gerar e julgar pode introduzir viés; não há garantia de correção automática.

Em RAG-R19/A, o juiz transformou condições em afirmações de estado ao decompor a resposta, contribuindo para faithfulness=0,500. A nota foi preservada; o ganho observado não comprova melhoria factual geral.

*Rubrica complementar: relevância Gemma 0,569 → 0,590 (+2,08 p.p.); critérios atendidos 21/34 → 22/34. Atendimento integral exige todos os critérios e fontes obrigatórias: 4/12 → 3/12. Esses números não são scores RAGAS. Prompt e busca mudam juntos; uma rodada não isola causas nem produz significância estatística.

Achados, decisão e reprodução

Recuperação e fumaça

Abaselinerecuperoumanutençãoem lugar da regra protetiva. A candidata recuperou o trecho pertinente, mas Gemma ainda omitiu afastamento e equipe. A melhoria é parcial.

Apoios inválidos

ArespostasobreIP66/IP55 permaneceu retida por trecho não confirmado. O controle evita exibir uma resposta com citação inválida, mas causa perda de utilidade.

Extrapolações

GPT-OSS completou uma condição de retomada ausente nos chunks e perdeu uma condição de interrupção segura. As notas penalizam esses casos. Fonte válida não assegura fidelidade de toda a resposta.

Decisão: manter Gemma, busca semântica e prompts v2 como padrão. A candidata híbrida/v3 fica optativa, pois o pequeno ganho agregado veio do caso adversarial e o atendimento integral caiu. Os três ataques testados não comandaram a execução; isso não prova imunidade nem aprovação integral das respostas.

Rastreabilidade: evals/sprint4 contém protocolo, adendo, perguntas, contextos, gerações brutas, citações, notas e scores. docs/relatorio_rag.md e docs/relatorio_modelos.md detalham a metodologia. A regressão e as instruções de execução estão no README; a interface permanece Gradio, sem alteração visual nesta etapa.

Reprodução: evals/avaliar_ragas.py executa o juiz em ambiente separado, com versões fixadas em evals/requirements-ragas.txt e lock da rodada. evals/gerar_relatorios_sprint4.py gera os documentos dos scores salvos sem inferência. O procedimento está em docs/avaliacao_ragas.md; o índice e a aplicação em docs/rag.md.